

20 ideas de agentes, con el Juez en contra

Preparado el 11 de septiembre de 2026 para el equipo Tereré Driven Development. Hackathon Agents, Everywhere, sábado 12, 4 horas 15 minutos de build.

Cómo leer este documento

Cada idea tiene tres partes: qué es, por qué el entorno es esencial (que es lo que mide el criterio 2), y lo que diría **el Juez**.

El Juez es un personaje. Evaluó cientos de proyectos de agentes, está cansado, vio todo dos veces y no le impresiona nada que suene bien. No es malo: su trabajo es encontrar el agujero antes que el jurado real. Si una idea sobrevive al Juez, sobrevive al hackathon.

Las cinco categorías no son temáticas. Son **las cinco razones por las que algo no se puede hacer en un cuadro de chat**, que es literalmente la definición de puntaje 5 en el criterio 2:

1. **Ve lo que no podés pegar.** DOM en vivo, pantalla, audio, telemetría de tu trabajo.
2. **Actúa donde no estás.** De fondo, mientras dormís, en otro sistema.
3. **Aparece cuando no lo pedirías.** El valor es el timing de la intervención.
4. **Vive entre varias personas.** Su valor sale de estar en el medio de un grupo.
5. **Tiene presencia física o voz.** Una sala, un mostrador, manos ocupadas.

Si tu idea no entra en ninguna de las cinco, es un chatbot con disfraz. El Juez lo va a ver.

Viabilidad se mide contra la realidad: 4 personas, 3 codeando la mayor parte del tiempo, 4h15m, video grabado a las 14:30.

Antes de las ideas: el Juez te discute las premisas

Estas son cosas que dijiste o asumiste en estos días. El Juez las ataca una por una.

“Quiero que sea innovador, que no haya otro igual.” Ese no es el objetivo. El objetivo es 5 en criterio 2 **y** funcionando a las 15:30. “Que no haya otro igual” te empuja a lo raro, y lo raro suele ser raro porque no sirve. Los proyectos que ganan hackathons no son los más originales: son los que tienen una idea clara ejecutada sin errores en un video de dos minutos. La originalidad es un medio para el criterio 2, no un fin.

“Es global, entonces la idea tiene que ser global.” Falso dilema. Lo global se gana con el encuadre, no con el dominio. Un juez de Berlín entiende “las facturas electrónicas se rechazan por datos mal cargados” en cinco segundos. Lo que no entiende es por qué tu agente de productividad genérico es distinto de los otros cuarenta que vio hoy.

“Somos 4 a 5 personas.” Sos 4. Y uno se va del código a las 14:00 para hacer video, descripción y post. Son 3 developers durante 3 horas efectivas. Cualquier idea con más de una integración no trivial no llega.

“La idea tiene que ayudar tanto a desarrolladores como a personas normales.” No. Elegí uno. Un agente que sirve a los dos no sirve bien a ninguno, y el criterio 4 pregunta por “valor claro para los usuarios previstos”, en singular. Definí el usuario en una frase o no tenés proyecto.

“Claude me recomendó SIFEN cuatro veces.” Sí, y eso fue sesgo. Es tu dominio y era el camino fácil. KuatiaGuard es un validador de formularios con un LLM adentro. Un jurado lo puede leer como autocompletado. Ojo con confundir “lo conozco” con “es lo mejor”.

Categoría 1: Ve lo que no podés pegar

1. Sesión, no página (global)

Qué es. Extensión de navegador que lee el grafo de pestañas y el historial de la última hora, reconstruye qué estabas intentando hacer (“estás comparando cuatro proveedores de hosting por precio y latencia a Paraguay”) y lo termina: arma la comparación, rellena el formulario que abandonaste, o te dice cuál te faltó mirar.

Por qué el entorno es esencial. Catorce pestañas no se pegan en un chat. La tarea está implícita en la navegación, nunca la escribiste.

El Juez. “Reconstruir la intención de catorce pestañas es adivinación con buena prensa. En tu demo va a funcionar porque vos armaste las pestañas. Mostrame que funciona con las pestañas de otra persona. Y aviso: ‘agente de navegador’ lo vi treinta veces hoy. Lo único que te salva es que el tuyo mire la sesión entera y no una página.”

Viabilidad. Media. La API de pestañas es trivial. La inferencia de intención es el riesgo, y los falsos positivos en el video quedan muy mal.

Puntaje estimado. C1 3, C2 4, C3 3, C4 3.

2. Lo que dicen contra lo que muestran (global)

Qué es. Durante una reunión con pantalla compartida, el agente mira la pantalla y escucha la transcripción. Avisa cuando lo que se dice contradice lo que se muestra: “dijiste que el churn bajó, la slide muestra que subió”.

Por qué el entorno es esencial. Necesita acceso simultáneo a píxeles y audio en tiempo real. No hay forma de pegar eso en un chat.

El Juez. “Técnicamente hermosa, imposible en cuatro horas. Captura de pantalla, transcripción y comparación semántica en tiempo real. Vas a llegar a las 15:30 con un video simulado y te doy 1 en criterio 1. Guardala para otro hackathon.”

Viabilidad. Baja.

Puntaje estimado. Si funcionara: C2 5. Realista: C1 1, y con eso se hunde todo.

3. Corrección antes del rechazo (Paraguay, KuatiaGuard)

Qué es. Extensión que vive en el portal de facturación electrónica. Mientras la persona carga la factura, valida contra las reglas del SIFEN, marca lo que va a ser rechazado y corrige el campo en el lugar.

Por qué el entorno es esencial. Ve el formulario en vivo y escribe de vuelta en él. En un chat habría que copiar cuarenta campos.

El Juez. “Es un validador de formularios con un LLM. Lo llamás agente pero no decide nada, chequea reglas. Y el entorno no es esencial, es conveniente: podría ser un botón ‘validar’ dentro del ERP. Dame el motivo por el que esto es un patrón nuevo y no autocompletado inteligente.”

Cómo se le contesta. Si el agente no solo valida sino que *resuelve*: consulta el RUC, propone la razón social correcta, explica la regla que se rompería, y aprende los patrones de cada cliente. Ahí hay decisión. Pero esa es la versión difícil, no la de cuatro horas.

Viabilidad. Media-alta la versión validador, media la versión agente.

Puntaje estimado. C1 4, C2 3 (validador) o 4 (agente), C3 4, C4 4.

4. El loop de prueba y error (global)

Qué es. Agente que mira tu terminal. Detecta que corriste el mismo comando cinco veces con variaciones chicas, que es el patrón clásico de estar manoteando. En vez de un consejo genérico, lee las cinco salidas y te dice qué significa el patrón de fallas.

Por qué el entorno es esencial. Necesita la secuencia de comandos y salidas en el tiempo. Nadie pega cinco intentos en un chat.

El Juez. “Es un asistente de código con un trigger. El espacio está saturado hasta la náusea. Lo que te salva es que la detección del patrón sea genuinamente buena y aparezca sin que nadie le hable. Si en el video alguien le escribe una pregunta, perdiste el criterio 2 en el acto.”

Viabilidad. Alta. Un hook de shell y parseo de logs.

Puntaje estimado. C1 4, C2 3, C3 4, C4 4.

Categoría 2: Actúa donde no estás

5. Radar de licitaciones (Paraguay, Tapehã)

Qué es. Monitorea los datos abiertos de la DNCP, cruza cada licitación nueva con el perfil de la empresa, y avisa por Telegram sin que nadie pregunte, con análisis de por qué califica y cuándo cierra.

Por qué el entorno es esencial. Se dispara por un evento externo. El usuario no sabía que había algo que preguntar.

El Juez. “Es un feed RSS con un LLM que escribe el resumen. La proactividad es un cron. Convenceme de que hay una decisión del agente entre el evento y la notificación, no solo un filtro. Y si me mostrás Telegram, el canal es un contenedor: podría ser un mail.”

Cómo se le contesta. El agente hace lo que un filtro no puede: mira adjudicaciones pasadas para identificar competidores probables, estima chances, y arma el checklist de requisitos. Y Telegram deja de ser contenedor si el usuario responde “preparala” y el agente actúa.

Viabilidad. Alta. Datos abiertos, estándar OCDS, bot de Telegram en minutos.

Puntaje estimado. C1 5, C2 3 (filtro) o 4 (con razonamiento), C3 4, C4 4.

6. La cola de decisiones de la mañana (global)

Qué es. Agente de navegador que trabaja de noche en un portal sin API: gobierno, banco, ERP viejo. Hace todo lo que puede solo, y a la mañana deja una cola con únicamente lo que necesita a un humano: “hice cuarenta, necesito que decidas tres”.

Por qué el entorno es esencial. Actúa mientras dormís. El valor es el filtrado de qué requiere tu criterio y qué no.

El Juez. “Me encanta el patrón. Pero ‘de noche’ en un hackathon de cuatro horas se demuestra con un timelapse falso. ¿Cómo me probás que el agente realmente decidió qué escalar y qué resolver? Necesito ver el criterio de escalamiento explícito, no el resultado. Si me mostrás ‘hice cuarenta’ sin mostrarme cómo eligió las tres, es magia y la magia puntúa 2.”

Viabilidad. Media. Browser use es frágil y un portal real puede cambiar.

Puntaje estimado. C1 3, C2 5, C3 3, C4 5.

7. Cobranzas mientras atendés (LATAM)

Qué es. Agente que negocia planes de pago por mensajería con clientes morosos mientras el dueño atiende el local. El dueño solo aprueba las condiciones finales.

Por qué el entorno es esencial. Actúa en paralelo al humano, en el canal donde el deudor ya está.

El Juez. “Chatbot de cobranzas. Los hay a patadas, y hay tres empresas paraguayas vendiendo exactamente esto. La única parte agéntica es negociar con límites, y eso es un prompt con reglas. El dueño ‘aprobandando’ es un botón. ¿Dónde está la sorpresa?”

Viabilidad. Alta.

Puntaje estimado. C1 4, C2 2, C3 3, C4 4.

8. El PR huérfano (global)

Qué es. GitHub App que vigila los pull requests. Cuando uno lleva 24 horas sin revisión, el agente hace una primera pasada, etiqueta al reviewer correcto con un resumen de tres líneas, y si es trivial propone el merge.

Por qué el entorno es esencial. Actúa por un timer que nadie puso, dentro del repo.

El Juez. “GitHub ya hace la mitad de esto. La parte ‘elige al reviewer correcto’ es lo único nuevo y es un heurístico sobre git blame. Saturado, y encima compite contra el producto de la plataforma donde vive.”

Viabilidad. Alta.

Puntaje estimado. C1 4, C2 2, C3 4, C4 3.

Categoría 3: Aparece cuando no lo pedirías

9. Detector de trabado (global)

Qué es. Agente en el editor. Nunca le hablás. Mira el ritmo real del trabajo: mismo archivo abierto veinte minutos, tests en loop, el mismo error tres veces, cero commits. Cuando el patrón se enciende, aparece con ayuda.

Por qué el entorno es esencial. La señal es tu comportamiento, no texto. Y el momento lo elige él, justo cuando vos ya no estás en condiciones de formular una buena pregunta.

El Juez. “Ver la idea 4, mismo problema de saturación. Y una pregunta que no tenés respondida: ¿cómo distinguís ‘trabado’ de ‘pensando’? Si interrumpís a alguien que está pensando, el agente es una molestia. Molestia es criterio 4 en 2.”

Viabilidad. Alta.

Puntaje estimado. C1 4, C2 3, C3 4, C4 3.

10. Compromisos incompatibles (global)

Qué es. Lee calendario, mail y chat. Detecta cuando aceptaste dos cosas que son semánticamente incompatibles, no un doble booking: prometiste una entrega el viernes y aceptaste un viaje de tres días desde el miércoles. Avisa en el momento exacto del segundo “sí”.

Por qué el entorno es esencial. Cruza fuentes que vos nunca cruzás, e interviene en el instante en que se crea el conflicto.

El Juez. “Buena idea. Integrar tres fuentes en cuatro horas es suicidio. Y la inferencia de ‘incompatible’ va a tener falsos positivos que en el demo te dejan mal parado. Bajá a dos fuentes o no lo hagas.”

Viabilidad. Media-baja.

Puntaje estimado. C1 3, C2 4, C3 3, C4 4.

11. La decisión que nadie anotó (global)

Qué es. En un grupo de Slack o Telegram, detecta cuando un hilo llegó a una decisión real (“ok, dale”, “listo, hacemos X”) y nadie la registró. La anota y publica una confirmación de una línea.

Por qué el entorno es esencial. Vive en el grupo, lee el flujo, se activa por un patrón que ningún individuo notaría.

El Juez. “Es un resumidor de Slack con un trigger más fino. Lo vi. Lo que lo salvaría: que además de detectar la decisión, detecte que **contradice una decisión anterior**. Eso no lo vi. Sin eso, 2. Con eso, 4.”

Viabilidad. Alta.

Puntaje estimado. C1 4, C2 2 (solo detección) o 4 (con contradicción), C3 4, C4 4.

12. Vas a repetir el error (global)

Qué es. Agente con memoria de incidentes pasados (postmortems, historial de git) que mira lo que estás haciendo ahora e interviene cuando el patrón coincide: “la última vez que tocaste este archivo un viernes a las seis, rompiste producción”.

Por qué el entorno es esencial. Necesita memoria longitudinal más observación en tiempo real.

El Juez. “Depende de historial que no tenés en un hackathon. Vas a sembrar tres incidentes falsos y detectar el que sembraste. Yo lo veo. Además, este es el patrón ‘Clippy con memoria’ y todos sabemos cómo terminó Clippy.”

Viabilidad. Media.

Puntaje estimado. C1 3, C2 4, C3 3, C4 3.

Categoría 4: Vive entre varias personas

13. Deriva de definiciones (global)

Qué es. Vive en un grupo. No responde nada. Construye en silencio un glosario de cómo cada persona usa cada término, y solo interviene cuando detecta que dos personas están usando la misma palabra con significados distintos: “cuando Juan dice ‘cliente’ se refiere al usuario final, cuando María lo dice se refiere a la empresa que paga. Llevan doce mensajes discutiendo cosas diferentes”.

Por qué el entorno es esencial. Necesita estar en todos los mensajes, necesita varios humanos, y el valor es interrumpir en el momento justo. Las tres condiciones se rompen si lo sacás del grupo.

El Juez. “La primera idea de esta lista que no vi antes. Bien. Ahora: ¿con qué frecuencia pasa de verdad? Si pasa una vez por semana, tu demo es guionado y se nota. Y el riesgo de falso positivo es brutal: si el agente interrumpe para decir ‘no están de acuerdo’ cuando sí lo están, es peor que no tenerlo. Mostrame la precisión, no el concepto.”

Viabilidad. Media. La arquitectura es simple: escuchar, mantener estado, intervenir por patrón. La precisión del detector es lo difícil.

Puntaje estimado. C1 3, C2 5, C3 4, C4 4.

14. El stakeholder ausente (global)

Qué es. Vive dentro de un documento compartido. Mientras el equipo escribe una spec, comenta en el margen como la parte que no está en la sala: legales, soporte, el usuario final, el que va a mantener esto en dos años. No resume, objeta.

Por qué el entorno es esencial. Ve el documento cambiando en vivo y comenta donde la escritura ya está pasando.

El Juez. “Un prompt con rol, puesto en un comentario de Google Docs. ¿Es agente o es un reviewer con disfraz? Lo que lo salvaría: que el agente **elija qué stakeholder falta** según lo que se está escribiendo, no que vos se lo digas. Ahí hay una decisión. Sin eso, es un chatbox con margen.”

Viabilidad. Alta. Apps Script se arma rápido.

Puntaje estimado. C1 4, C2 3 (rol fijo) o 4 (elige rol), C3 3, C4 4.

15. Traspaso de turno (global y local)

Qué es. Agente presente en el turno de A y en el turno de B: mensajería más eventos del sistema. Escribe el traspaso que nadie escribe.

Por qué el entorno es esencial. Estuvo en los dos lados. Ninguno de los dos humanos estuvo completo.

El Juez. “¿Presente cómo? Si ‘presente’ significa que leyó el chat, es un resumen. Si significa que vio el sistema, tickets, eventos, alarmas, entonces sí. En cuatro horas vas a hacer la primera versión, y ‘resumen de turno’ lo hacen cinco productos.”

Viabilidad. Alta la versión débil.

Puntaje estimado. C1 4, C2 2, C3 3, C4 3.

16. La tarea sin dueño (global)

Qué es. En un grupo donde las tareas se reparten informalmente, detecta cuando algo se mencionó como necesario y nadie lo agarró. Después de N horas, propone un dueño con razonamiento: “esto lo hizo Carla las últimas tres veces”.

Por qué el entorno es esencial. Multi-persona. El hueco es invisible para cualquier individuo.

El Juez. “Es buena y es chica. Eso la hace construible. Pero es Asana con un LLM. Tu ángulo tiene que ser ‘propone dueño con razonamiento’, no ‘pregunta quién’. Lo segundo es un cron con carita.”

Viabilidad. Alta.

Puntaje estimado. C1 4, C2 3, C3 4, C4 4.

Categoría 5: Presencia física y voz

17. Ñe’ẽ, voz en guaraní (Paraguay)

Qué es. Agente de voz que toma pedidos en jopará para una despensa de barrio.

Por qué el entorno es esencial. El contexto es la lengua y la oralidad. Una dispensera que habla jopará no va a tipear en un chat en inglés.

El Juez. “Nadie más lo va a tener. Nadie más lo va a tener porque el reconocimiento de voz en guaraní falla uno de cada seis caracteres. En el video, o funciona y es el mejor proyecto del hackathon, o falla y es el más triste. No hay medio. ¿Estás dispuesto a apostar los cuatro criterios a un modelo que no controlás?”

Viabilidad. Baja.

Puntaje estimado. C1 2, C2 5, C3 3, C4 4. El 2 en C1 mata el promedio.

18. Manos ocupadas (global)

Qué es. Voz ambiental en un taller, cocina o laboratorio. Sin palabra de activación. Escucha el contexto y actúa: pone timers, dicta el siguiente paso, registra mediciones dichas en voz alta.

Por qué el entorno es esencial. Manos ocupadas, ojos ocupados, nadie tipea. La sala es la interfaz.

El Juez. “Alexa. Alexa existe hace diez años. ¿Qué hace tu agente que Alexa no? Si la respuesta es ‘entiende contexto’, mostrame el contexto que entiende. Y sin palabra de activación en un ambiente ruidoso, la transcripción es basura.”

Viabilidad. Media.

Puntaje estimado. C1 3, C2 3, C3 3, C4 3.

19. Recepción que agenda por voz (global)

Qué es. Tablet en la recepción de un consultorio que agenda turnos hablando.

Por qué el entorno es esencial. Lugar físico, voz.

El Juez. “Vapi lo hace en veinte minutos, y por eso hay doscientas startups haciendo exactamente esto. Criterio 2: 2. Puede estar muy bien ejecutado y no importa.”

Viabilidad. Alta.

Puntaje estimado. C1 4, C2 2, C3 3, C4 3.

20. La memoria de la sala (global)

Qué es. Un dispositivo físico con micrófono en una sala de reuniones presencial, no en una videollamada. Es la memoria de lo que se decidió ahí. Cuando alguien dice “qué habíamos decidido de X”, contesta en voz alta. Nadie abre una laptop.

Por qué el entorno es esencial. Sala física, sin pantallas, presente a través de muchas reuniones.

El Juez. “Es un notetaker con parlante. La parte física es cosmética: podrías hacer lo mismo en Zoom. A menos que la sala aporte algo que la videollamada no: quién estaba presente físicamente, qué se dijo en el pasillo después. Y con hardware en cuatro horas, el riesgo es que a las 14:00 estés soldando.”

Viabilidad. Baja-media.

Puntaje estimado. C1 3, C2 3, C3 3, C4 3.

Tabla resumen

#	Idea	Cat.	Alcance	Viab.	C2	Total est.	Veredicto del Juez
1	Sesión, no página	1	Global	Media	4	13	Adivinación bien vestida
2	Dicen contra muestran	1	Global	Baja	5	Inviable	Otro hackathon
3	Corrección antes del rechazo	1	PY	Media-alta	3-4	15-16	Validador, salvo versión agente
4	Loop de prueba y error	1	Global	Alta	3	15	Saturado
5	Radar de licitaciones	2	PY	Alta	3-4	16-17	Cron, salvo con razonamiento
6	Cola de decisiones	2	Global	Media	5	16	Gran patrón, demo difícil de probar
7	Cobranzas	2	LATAM	Alta	2	13	Existe
8	PR huérfano	2	Global	Alta	2	13	Compite con GitHub
9	Detector de trabado	3	Global	Alta	3	14	Molestia potencial
10	Compromisos incompatibles	3	Global	Media-baja	4	14	Demasiadas fuentes
11	Decisión no anotada	3	Global	Alta	2-4	14-16	Solo con contradicción
12	Vas a repetir el error	3	Global	Media	4	13	Clippy con memoria
13	Deriva de definiciones	4	Global	Media	5	16	Nueva. Mostrame precisión

14	Stakeholder ausente	4	Global	Alta	3-4	14-15	Solo si elige el rol
15	Traspaso de turno	4	Ambos	Alta	2	12	Resumen
16	Tarea sin dueño	4	Global	Alta	3	15	Asana con LLM
17	Voz en guaraní	5	PY	Baja	5	14	Todo o nada
18	Manos ocupadas	5	Global	Media	3	12	Alexa
19	Recepción por voz	5	Global	Alta	2	12	Doscientas startups
20	Memoria de la sala	5	Global	Baja-media	3	12	Notetaker con parlante

Total estimado sobre 20. Los totales son opinión, no medición.

Lo que el Juez elige, y por qué no elige lo que vos elegirías

El Juez no elige la más innovadora. Elige la que suma más puntos **dado que va a existir a las 15:30**.

Primera: la 13, deriva de definiciones. Es el único 5 genuino en criterio 2 que se puede construir. Condición innegociable: un grupo de prueba guionado con tres conversaciones donde el desacuerdo semántico es real y verificable, y un detector con umbral alto que prefiera callarse a equivocarse. Si el equipo no está dispuesto a invertir una hora en el dataset de prueba, no la hagan.

Segunda: la 6, cola de decisiones. El patrón es un 5 y resuelve un problema que cualquier juez del mundo reconoce. El riesgo es la honestidad del demo. Se resuelve mostrando el criterio de escalamiento en pantalla mientras corre: “esto lo resuelvo porque X, esto lo escalo porque Y”. Si se ve la decisión, deja de ser magia.

Tercera: la 5 con razonamiento, radar de licitaciones. La más segura. Sube de 3 a 4 en criterio 2 si el agente hace algo que un filtro no puede: analizar competidores por adjudicaciones pasadas y armar el checklist. Y si el usuario contesta “preparala” y el agente actúa, Telegram deja de ser contenedor.

La idea que sale de juntar dos

Las ideas 11, 13 y 16 tienen **la misma arquitectura**: un agente que escucha un grupo, mantiene estado, y solo interviene cuando un patrón se enciende. Lo que cambia es el patrón: decisión no anotada, deriva de definiciones, tarea sin dueño.

Eso significa que podés construir la arquitectura una sola vez y enchufarle tres detectores. Grabás el video con el detector que mejor funcione a las 14:30. Si el de definiciones no llega a la precisión que necesita, el de tareas sin dueño está ahí. Es la única manera de apostar a un 5 en criterio 2 con una red de seguridad debajo.

El Juez lo aprueba con una condición: en el video se muestra **un** detector funcionando de verdad, no tres a medias.

Las cinco preguntas que el Juez le hace al equipo mañana a las 11:00

Contestenlas antes de escribir la primera línea. Si alguna no tiene respuesta clara, la idea está mal definida.

1. **¿Qué decide el agente que un **if** no decidiría?** Si la respuesta es “nada”, es una automatización, y automatización es 1 en criterio 2.
2. **¿Qué pasa con el video si le sacás el entorno?** Si el mismo demo se podría hacer en ChatGPT copiando y pegando, el entorno es un contenedor. Puntaje 2.
3. **¿Quién le escribe al agente?** Si en el video alguien le tipea una pregunta, es un chatbot. El agente tiene que actuar por lo que ve, no por lo que le piden.
4. **¿Qué controla el usuario si el agente se equivoca?** Criterio 4 pide “claro y controlable”. Un agente sin botón de deshacer o sin explicación de por qué hizo lo que hizo pierde ahí.
5. **¿Qué parte del repo existía ayer?** Tienen que poder contestarlo con el historial de commits. Si dudan, es un problema de elegibilidad, y eso no puntúa: descalifica.

Última cosa del Juez

“Todo lo que leíste es opinión con argumentos. Discutanla, rómpanla, pero rómpanla con argumentos y no con entusiasmo. El único que no acepta argumentos es el reloj.”